

Problema	Estrategia propuesta	Prioridad	Explicacion	Semana
Precio unitario: 3.40% datos faltantes	Eliminación de filas (MCAR, <5%)	Alta	Al ser MCAR y estar por debajo del umbral del 5%, eliminar no introduce sesgo ni distorsiona la distribución. Prioridad: precio_unitario es un campo transaccional core que afecta cálculos financieros directos (ingresos, márgenes), por lo que su integridad es crítica para el negocio.	4
monto_compra: 3.40% datos faltantes	Recalcular monto_compra = precio_unitario × unidades_vendidas una vez tratado precio_unitario (en vez de imputar de forma independiente)	Alta	la tabla cruzada contra precio_unitario mostró una correspondencia exacta 1 a 1 (100% de los nulos de monto_compra coinciden con nulos de precio_unitario), confirmando que no es un valor independiente sino una dependencia funcional directa. Por eso no se debe imputar monto_compra con una mediana por grupo (eso "inventaría" un valor cuando en realidad se puede derivar matemáticamente), sino recalcularlo a partir de precio_unitario y unidades_vendidas una vez que precio_unitario esté tratado. Prioridad: sigue siendo el campo base para reportes de ingresos y ventas; un error o una imputación artificial aquí se propaga a todo análisis financiero.	4
ciudad_tienda: 4.70% datos faltantes	Eliminación de filas (MCAR, <5%)	Media	MCAR y bajo porcentaje permiten eliminar sin pérdida significativa. Prioridad: es un campo descriptivo/geográfico, útil para segmentación pero no crítico para cálculos financieros, de ahí la prioridad media.	4
correo_cliente: 16.40% datos faltantes	Columna indicadora, sin imputar (MNAR sospechado)	Media	Se probó la tasa de faltantes por categoria_producto (16.0%-16.9%), canal_compra (15.7%-17.6%), metodo_pago y nivel_lealtad, todas parejas sin grupos que se disparen — descarta MAR. Se concluye MNAR sospechado: el cliente decide no dar su correo (no obligatorio en checkout), ligado al valor mismo que falta. No se imputa (inventaría contacto falso); se conserva el faltante con columna indicadora (correo_cliente_faltante). Prioridad media: afecta contacto/marketing, no cálculos financieros core.	4
nivel_satisfaccion: 7.60% datos faltantes	Imputación por grupo según canal_compra (MAR)	Media	El canal "app" muestra 19.9%-21.0% de faltantes en las seis categorías de producto, frente a ~3% en los demás canales, aislando a canal_compra como variable explicativa (MAR confirmado). Se imputa con la moda por canal para respetar ese patrón. Prioridad media: afecta experiencia de cliente, no cálculos financieros core. Se recomienda reportar al área de producto el problema de captura en la app.	4
Comentario_cliente: 14.20% datos faltantes	MNAR, con columna indicadora	Baja	Se probó la tasa de faltantes por categoria_producto, canal_compra, metodo_pago y nivel_lealtad (todas ~14.0%-14.3%, sin grupos que se disparen), descartando MAR. Se concluye MNAR sospechado: dejar comentario es una acción voluntaria del cliente, ligada al valor mismo que falta. No se imputa (inventaría una opinión falsa); se conserva el faltante y se agrega columna indicadora (comentario_cliente_faltante) como señal para análisis posterior.	4

monto_compra: 1.10% falsos completos	Conversión a numérico con pd.to_numeric(errors="coerce") para revelar los falsos completos como nulos reales; luego recalcular monto_compra = precio_unitario × unidades_vendidas	Alta	El dato aparentaba estar completo pero tenía formato de texto no numérico (símbolos, separadores mal interpretados), ocultando su verdadero estado de faltante. Convertir con coerce expone esos casos como NaN, permitiendo tratarlos con la misma lógica ya validada para los nulos reales de monto_compra (dependencia directa de precio_unitario). Prioridad alta: mientras el dato esté mal tipado es inutilizable para cálculos financieros, y un falso completo es más riesgoso que un nulo explícito porque puede pasar desapercibido en el análisis.	4
Categoría producto 38% datos inconsistentes	Normalización de nombres	Alta	La normalización nos permitirá unificar los datos que ahora están bajo diferentes formatos de escribir su categoría de manera efectiva	3
ciudad_tienda: 47.0% datos inconsistentes	Normalización de nombres	Alta	A tener datos de la misma ciudad bajo diferentes nombres, se dificulta el análisis regional del mercado en dicha zona, afectando la toma de decisiones. Por esto podemos afirmar que al normalizar todos los datos bajo nombres de ciudad únicos, tendremos una visión más acertada sobre el alcance de Novamarket	3
Precio_unitario: 1.00% valores > 10 millones	Convertir los valores 50,000,000 y 999,000,000 a NaN (son placeholders, no errores de dígito); tratar como nulos con la misma estrategia ya definida para precio_unitario (eliminación, MCAR)	Alta	El 99%+ de los 6,210 casos se concentra en solo dos valores exactos, no en un rango disperso — confirma placeholders, no errores de captura. Prioridad alta: distorsionan cálculos de ingresos mientras no se corrijan.	7
Edad cliente 4.3% datos sobre 120	Eliminación de filas (MCAR, <5%)	Media	Se probó contra canal_compra, categoría_producto, metodo_pago y nivel_lealtad; todas parejas (~2.9%), descartando MAR. El patrón de valores centinela (150/200) sugiere un problema técnico de captura, no una decisión del cliente, por lo que se descarta MNAR y se sostiene MCAR. Al estar bajo el 5%, eliminar no introduce sesgo.	7
Precio_unitario: 3.10% valores < 0	Aplicar .abs() para corregir el signo	Alta	Los cuartiles del valor absoluto de los negativos (mediana ~313,400) coinciden casi exactamente con los del resto del dataset (mediana ~315,200) — confirma error de signo, no dato corrupto. Prioridad alta: distorsiona sumas y promedios de ingresos mientras no se corrija.	7
Unidades_vendidas: 2.90% valores < 0	Aplicar .abs() para corregir el signo	Alta	Los negativos son solo -1 y -3, valores que caen justo dentro del rango típico de compra (mediana 2, IQR 1-3). Confirma error de signo, no dato corrupto. Prioridad alta: afecta directamente el cálculo de monto_compra (unidades × precio).	7
Fecha actualización stock fechas posteriores a la actual	Invaldar valor (NaT) + columna indicadora, sin eliminar fila	Alta	El desfase hacia el futuro es disperso (134-495 días, sin offset fijo), lo que descarta un bug sistemático corregible matemáticamente. No se elimina la fila completa porque el resto de columnas del registro sigue siendo válido; solo se invalida el campo de fecha para no distorsionar cálculos de antigüedad de stock.	6
fecha_actualizacion_stock: 10.30% stock sin actualizar hace +180 días	Crear columna indicadora stock_desactualizado (booleana) sin modificar la fecha original; reportar al área de inventario para verificación manual	Media	No es un error de dato sino una señal operativa (stock que no se ha revisado en tiempo); marcar en vez de modificar preserva la información útil. Prioridad media: relevante para gestión de inventario, pero no invalida el dato ni afecta cálculos financieros directos.	6

ID pedido con 3.17% de duplicados	Eliminación de duplicados (drop_duplicates, keep="first")	Alta	Las 40,000 filas involucradas en duplicado de id_pedido coinciden exactamente con las 40,000 filas de duplicado de fila completa, descartando colisión de ID. Son duplicados reales del mismo pedido.	
correo_cliente: 24.50% correos inválidos (sin @)	Corrección con regex: reemplazar el punto entre clienteNNNN y el dominio por @; los ~25 casos restantes que no calcen con el patrón se tratan como faltantes (columna indicadora)	Media	El patrón cubre 51,532 de 51,557 casos (99.95%): todos siguen la forma clienteNNNN.dominio, sin tasa desproporcionada por categoría, canal, método de pago o nivel de lealtad — confirma error de formato uniforme y recuperable, no dato perdido. Prioridad media: afecta contacto con el cliente, no cálculos financieros core.	6
Fecha pedido con 2.58% fechas en el futuro	Invalidar valor (NaT), sin eliminar fila	Alta	Desfase disperso (134-495 días), no corregible matemáticamente. Se recalculó con formato explícito, corrigiendo el conteo original. Prioridad alta por afectar análisis de ventas por fecha.	6
fecha_pedido: fechas inválidas 3.55%	Tratar como nulos: 00/00/0000 (placeholder) → NaT directo; fechas imposibles (30/02, 31/04, mes 13) → NaT vía errors="coerce"; documentar y reportar al área de sistemas el origen del error	Alta	Se identificaron 4 patrones fijos y repetidos (placeholder 00/00/0000, mes 13, día 30 de febrero, día 31 de abril) tras corregir primero un problema de formato mixto (ISO vs día/mes/año) que inflaba el conteo real. No son corregibles matemáticamente, requieren tratarse como faltantes. Prioridad alta: fecha_pedido es clave para reportes temporales de ventas.	6
16.4% de Fechas con formato año-mes-día	Estandarización de formato (reparseo a datetime único)	Media	La fecha es válida pero está en un estándar distinto. Se repareasea con formato explícito y se unifica a un solo tipo datetime, sin perder registros. Le damos prioridad media porque no compromete cálculos si se corrige antes del análisis.	6
canal_compra: 51.85% inconsistencia en nombres	Normalización de texto (.strip().lower(), sin tildes) y consolidación a las 4 categorías reales: app, marketplace, tienda, web	Alta	Tras normalizar, las 331,845 filas se consolidan sin pérdida en 4 categorías reales con distribución pareja (~160,000 cada una), confirmando que es solo un problema de formato, no de datos distintos. Prioridad alta: canal_compra es variable base para segmentar prácticamente todo el análisis (ya usada en diagnósticos MAR de otras columnas).	4
Método de pago 51.85% de nombres inconsistentes	Normalización de texto (minúsculas, sin tildes/espacios)	Alta	Hay variantes de escritura del mismo valor real. Se unifica con normalización de texto, sin perder registros. Prioridad media porque no compromete cálculos financieros directamente, solo agrupaciones y reportes por categoría.	4